

Universität Bremen

Master Thesis

From Street View to Aerial View: Transfer Learning for Drone-Based *Aedes* Breeding Site Detection

Faculty 3 - Mathematics and Computer Science

Master Computer Science

Author
Mail

Berke Karaduman [Matr.-Nr.]
berkekrdmn96@outlook.com

First Examiner
Second Examiner

Prof. Dr. Peter Haddawy
Dr. Thomas Barkowsky

Version

2025-12-23

Danksagung

Hiermit möchte ich mich herzlich bei allen bedanken, die mich während der Erstellung dieser Masterarbeit unterstützt haben.

Besonderer Dank gilt meinem Erstprüfer Prof. Dr. Peter Haddawy für die fachliche Betreuung und die hilfreichen Hinweise sowie meinem Zweitprüfer Dr. Thomas Barkowsky für das Interesse und das Feedback.

Darüber hinaus danke ich allen Kolleginnen und Kollegen sowie Freundinnen und Freunden für die Unterstützung, die motivierenden Gespräche und das konstruktive Feedback.

Zusammenfassung

Schlagwörter:

Inhaltsverzeichnis

Abbildungsverzeichnis	ii
Tabellenverzeichnis	iii
Acronyms	vi
Glossary	vii
1 Einleitung	1
2 Theoretischer Hintergrund	1
2.1 Aedes aegypti und urbane Brutstätten	1
2.2 Objekterkennung	2
2.3 Convolutional Neural Networks	3
2.3.1 Transfer Learning	4
2.3.2 YOLOv8	5
2.3.3 Bewertungsmetriken	6
2.4 Machine Learning Workflow	7

Abbildungsverzeichnis

Tabellenverzeichnis

Abbildungsverzeichnis

Tabellenverzeichnis

Acronyms

CNN Convolutional Neural Network. iv

Glossary

Transfer Learning Reuse of a pretrained model on a new task. iv

1 Einleitung

2 Theoretischer Hintergrund

In diesem Abschnitt wird der theoretische Hintergrund der vorliegenden Arbeit dargelegt. Zunächst werden die bevorzugten Brutstätten der *Aedes aegypti*-Mücke in urbanen Räumen sowie deren charakteristische visuelle Merkmale beschrieben. Anschließend werden die grundlegenden Konzepte der Objekterkennung und die in diesem Bereich etablierten tiefenlernungsbasierten Ansätze erläutert. Dabei werden insbesondere konvolutionelle neuronale Netze (CNN), das Prinzip des Transfer Learning sowie YOLO-basierte Detektionsmodelle betrachtet. Darüber hinaus werden im Kontext der Videodatenverarbeitung Ansätze zur Objektverfolgung (Object Tracking) sowie grundlegende Prinzipien der zeitlichen Datenverarbeitung vorgestellt, die zur Sicherstellung der zeitlichen Konsistenz und zur automatischen Ergänzung spärlich annotierter Sequenzen beitragen. Abschließend werden die verwendeten Bewertungsmetriken sowie der zugrunde liegende Lern- und Verarbeitungsablauf zusammengefasst, um das theoretische Fundament für den im folgenden Kapitel vorgestellten methodischen Ansatz zu schaffen.

2.1 *Aedes aegypti* und urbane Brutstätten

Aedes aegypti ist eine Mückenart, die vor allem in urbanen und stadtnahen Gebieten verbreitet ist und sich in unmittelbarer Nähe menschlicher Siedlungen vermehrt. Anstelle natürlicher Gewässer bevorzugt diese Art überwiegend kleine, meist menschengemachte Wasseransammlungen. Dadurch sind die Brutstätten von *Aedes aegypti* in der Regel eng mit künstlichen Objekten und Strukturen verbunden. Die Brutstätten von *Aedes aegypti* wurden in zahlreichen Studien im urbanen Kontext umfassend untersucht [1–4].

Typische Brutstätten in städtischen Umgebungen sind unter anderem Eimer, Behälter, Altreifen, Blumentöpfe sowie weitere kleine Gefäße, in denen sich Regen- oder Restwasser ansammeln kann. Diese Objekte weisen unterschiedliche Formen, Größen und Materialien auf und treten unter variierenden Umwelt- und Hintergrundbedingungen auf. In dieser Arbeit verwendeten Datensatz werden solche Objekte als potenzielle Brutstätten von *Aedes aegypti* annotiert.

Alle genannten Brutstätten sind in der Lage, Wasser zu speichern und bieten gleichzeitig Schutz vor direkter Sonneneinstrahlung. Zudem wird das Wasser in diesen potenziellen Brutstätten häufig nicht regelmäßig ausgetauscht, sondern beispielsweise nur nach Niederschlägen erneuert. Dadurch entstehen optimale Bedingungen für die Entwicklung der Larven von *Aedes aegypti*.

Die beschriebenen Brutstätten sind nicht ausschließlich auf *Aedes aegypti* beschränkt, sondern können auch von anderen Mückenarten genutzt werden. Dennoch ist *Aedes aegypti* insbesondere in urbanen Umgebungen eine der am häufigsten vorkommenden Arten.

2.2 Objekterkennung

Die Objekterkennung zählt zu den zentralen Aufgaben der Computer Vision und befasst sich mit der automatischen Identifikation und Lokalisierung von Objekten in digitalen Bildern oder Videosequenzen. Ziel ist es, relevante Objekte innerhalb einer Szene zu erkennen, ihnen eine semantische Klasse zuzuordnen und ihre Position mithilfe von Begrenzungsrahmen (Bounding Boxes) zu bestimmen. Im Gegensatz zur reinen Bildklassifikation, bei der lediglich das Vorhandensein eines Objekts festgestellt wird, kombiniert die Objekterkennung somit Klassifikations- und Lokalisierungsaufgaben.

Frühere Ansätze zur Objekterkennung basierten überwiegend auf handgefertigten Merkmalen sowie regelbasierten oder statistischen Methoden. Diese Verfahren stoßen jedoch insbesondere bei komplexen Szenen, variierenden Beleuchtungsverhältnissen und unterschiedlichen Objektgrößen an ihre Grenzen. Mit dem Fortschritt tiefenlernungsbasierter Methoden konnte die Leistungsfähigkeit von Objekterkennungssystemen deutlich gesteigert werden [5].

Moderne Objekterkennungsmodelle nutzen in der Regel Convolutional Neural Networks (CNN), die in der Lage sind, hierarchische visuelle Merkmale direkt aus den Daten zu erlernen. Dabei reichen die extrahierten Merkmale von einfachen Kanten und Texturen bis hin zu komplexen Formen und semantischen Strukturen. Diese Eigenschaft macht CNN-basierte Ansätze besonders geeignet für Anwendungen mit hoher visueller Variabilität.

Ein wesentlicher Aspekt der Objekterkennung ist die gleichzeitige Bewältigung von Klassifikation und räumlicher Lokalisierung. Während die Klassifikation bestimmt, zu welcher Kategorie ein Objekt gehört, beschreibt die Lokalisierung dessen Position innerhalb des Bildes. Diese Kombination ist insbesondere für Anwendungen wie Umweltüberwachung, Verkehrsanalysen sowie die Auswertung von Luft- und Drohnenaufnahmen von großer Bedeutung.

Im Rahmen dieser Arbeit wird die Objekterkennung als zentrale Methode zur automatischen Identifikation potenzieller Brutstätten von *Aedes aegypti* in drohnenbasierten Bild- und Videodaten eingesetzt. Die geringen Objektgrößen, komplexe Hintergründe und wechselnde Aufnahmeperspektiven stellen dabei besondere Herausforderungen dar und erfordern den Einsatz robuster, tiefenlernungsbasierter Detektionsverfahren. Aufbauend auf diesen Grundlagen werden in den folgenden Abschnitten die verwendeten Deep-Learning-Modelle und Ansätze detailliert erläutert.

2.3 Convolutional Neural Networks

Convolutional Neural Networks (CNNs) sind mehrschichtige, vorwärtsgerichtete neuronale Netzwerke, die speziell für die Verarbeitung gitterförmig strukturierter Daten wie Bilder entwickelt wurden. Aufgrund ihrer mehrstufigen Architektur eignen sich CNNs besonders gut für Aufgaben der Bildanalyse und Objekterkennung [6]. Eine typische CNN-Architektur besteht aus mehreren aufeinanderfolgenden Schichten, darunter Faltungs- (Convolution), Aktivierungs- und Pooling-Schichten sowie gegebenenfalls vollständig verbundene Schichten.

Die Faltungsschichten wenden lernbare Filter auf das Eingabebild an, um lokale Merkmale wie Kanten, Ecken oder Texturen zu extrahieren. Mit zunehmender Tiefe des Netzwerks werden diese einfachen Merkmale zu komplexeren und semantisch aussagekräftigeren Repräsentationen kombiniert. Dieser hierarchische Merkmalslernprozess bildet die Grundlage für den erfolgreichen Einsatz von CNNs in visuell anspruchsvollen Anwendungen wie der Objekterkennung.

Die Leistungsfähigkeit tiefer Convolutional Neural Networks wurde insbesondere durch die Arbeit von Krizhevsky et al. demonstriert, die mit der AlexNet-Architektur auf dem ImageNet-Datensatz signifikante Leistungssteigerungen gegenüber traditionellen Ansätzen erzielten [7]. Diese Ergebnisse trugen maßgeblich zur Etablierung tiefer CNN-Modelle in der Computer Vision bei und führten zu einer breiten Anwendung in verschiedensten visuellen Erkennungsaufgaben.

Im Gegensatz zu klassischen maschinellen Lernverfahren, bei denen relevante Merkmale häufig manuell und auf Basis von Domänenwissen entworfen werden, integrieren Convolutional Neural Networks die Merkmalsextraktion direkt in den Lernprozess. Dadurch sind CNNs in der Lage, problemrelevante und hierarchische visuelle Repräsentationen unmittelbar aus den Rohdaten zu erlernen. Dieser Ansatz führt insbesondere bei komplexen Szenen, variierenden Hintergrundbedingungen sowie bei der Detektion kleiner Objekte zu einer deutlich verbesserten Generalisierungsfähigkeit im Vergleich zu traditionellen Methoden des maschinellen Lernens [6, 8].

In der Objekterkennung bilden CNNs die zentrale Grundlage sowohl für die Klassifikation als auch für die räumliche Lokalisierung von Objekten. Die in dieser Arbeit eingesetzten Detektionsmodelle basieren auf CNN-Architekturen, die eine robuste Repräsentation visueller Merkmale über verschiedene Maßstäbe und Umgebungsbedingungen hinweg ermöglichen. Im folgenden Abschnitt wird erläutert, wie diese Grundprinzipien im Rahmen des Transfer Learning weitergenutzt werden.

2.3.1 Transfer Learning

Transfer Learning (TL) beschreibt einen Ansatz des maschinellen Lernens, bei dem ein vortrainiertes Modell als Ausgangspunkt für das Lernen einer neuen, jedoch verwandten Aufgabe verwendet wird. Ziel dieses Ansatzes ist es, bereits erlerntes Wissen aus einer Quellaufgabe (Source Task) auf eine Zielaufgabe (Target Task) zu übertragen und dadurch den Trainingsaufwand sowie den Bedarf an umfangreich annotierten Daten zu reduzieren [9, 10].

Die grundlegende Idee des Transfer Learning wurde erstmals von Bozinovski und Fulgosi bereits im Jahr 1976 im Kontext neuronaler Netze vorgestellt [9]. Seitdem hat sich Transfer Learning als ein zentrales Werkzeug etabliert, insbesondere zur Bewältigung von Szenarien mit begrenzter Datenverfügbarkeit [11]. Pan und Yang definieren Transfer Learning als den Versuch, die Lernleistung einer Zielprediktionsfunktion in einer neuen Domäne durch die Nutzung von Wissen aus einer anderen, verwandten Domäne zu verbessern [10].

Im Bereich der Bildverarbeitung und Objekterkennung wird Transfer Learning häufig in Kombination mit Convolutional Neural Networks eingesetzt. Dabei werden Modelle genutzt, die zuvor auf großen, allgemein gehaltenen Datensätzen wie ImageNet oder MS COCO trainiert wurden. Die früh erlernten Merkmale, wie Kanten, Texturen und einfache Formen, sind in vielen visuellen Aufgaben übertragbar und können als stabile Basis für neue Anwendungsfälle dienen.

Ein gängiger Ansatz im Transfer Learning besteht darin, bestimmte Schichten des vortrainierten Modells während des Trainings einzufrieren. Diese sogenannten *frozen layers* behalten ihre Gewichtungen bei und werden nicht weiter angepasst. Insbesondere die frühen Faltungsschichten eines CNNs werden häufig eingefroren, da sie für die Extraktion grundlegender visueller Merkmale verantwortlich sind [12]. Die späteren Schichten hingegen werden gezielt an die spezifische Zielaufgabe angepasst.

Im Kontext dieser Arbeit spielt Transfer Learning eine zentrale Rolle, da die verfügbaren Trainingsdaten für die Detektion potenzieller Brutstätten von *Aedes aegypti* nur begrenzt und teilweise spärlich annotiert sind. Durch die Nutzung vortrainierter Modelle kann dennoch eine robuste Merkmalsrepräsentation erlernt werden, ohne ein Modell vollständig von Grund auf neu trainieren zu müssen. Dieser Ansatz bildet die Grundlage für den Einsatz moderner Detektionsarchitekturen wie YOLO, die im nächsten Abschnitt detailliert vorgestellt werden.

2.3.2 YOLOv8

Die YOLO-Architektur (You Only Look Once) zählt zu den bekanntesten einstufigen (one-stage) Ansätzen im Bereich der Objekterkennung. Ursprünglich wurde YOLO von Redmon et al. vorgestellt, um die Klassifikation und Lokalisierung von Objekten in einem einzigen Vorwärtsdurchlauf eines neuronalen Netzes zu vereinen und damit eine Echtzeit-Objekterkennung zu ermöglichen [13]. Dieser Ansatz bietet insbesondere im Hinblick auf die Verarbeitungsgeschwindigkeit deutliche Vorteile gegenüber zweistufigen Detektionsverfahren.

Im Laufe der Zeit wurde die YOLO-Architektur kontinuierlich weiterentwickelt, wobei jede neue Version architektonische Verbesserungen sowie optimierte Trainings- und Verlustfunktionen einführte [14, 15]. In dieser Arbeit wird YOLOv8 verwendet, eine von Ultralytics entwickelte, moderne YOLO-Variante, die sich durch eine vereinfachte Architektur, hohe Flexibilität und verbesserte Leistungsfähigkeit auszeichnet [16].

Ein zentrales Merkmal von YOLOv8 ist der Einsatz eines anchor-freien Detektionsansatzes. Im Gegensatz zu früheren YOLO-Versionen entfällt die Verwendung vordefinierter Anchor-Boxen, wodurch das Modell besser auf unterschiedlich große Objekte reagieren kann und der Trainingsprozess vereinfacht wird. Darüber hinaus nutzt YOLOv8 eine sogenannte decoupled head-Struktur, bei der Klassifikation und Lokalisierung getrennt voneinander gelernt werden. Dies führt zu einer stabileren Optimierung und einer verbesserten Detektionsgenauigkeit.

Architektonisch besteht YOLOv8 aus einer optimierten Backbone-Struktur zur Merkmalsextraktion, einem Neck-Modul zur mehrskaligen Merkmalsfusion sowie einem Head-Modul zur Ausgabe der finalen Detektionsergebnisse. Diese Struktur ist insbesondere für die Erkennung kleiner Objekte in komplexen Szenen geeignet, wie sie typischerweise in drohnenbasierten Bild- und Videodaten auftreten. Für die vorliegende Arbeit ist dies von besonderer Bedeutung, da potenzielle Brutstätten von *Aedes aegypti* in Luftaufnahmen häufig nur in sehr kleinem Maßstab sichtbar sind.

Zur Gewährleistung der Reproduzierbarkeit der Ergebnisse werden in dieser Arbeit vortrainierte YOLOv8-Modelle verwendet, die von Ultralytics bereitgestellt werden. Die Kombination aus hoher Inferenzgeschwindigkeit, moderner Trainingsinfrastruktur und robuster Leistungsfähigkeit macht YOLOv8 zu einer geeigneten Grundlage für die automatische Objekterkennung in drohnenbasierten Videoaufnahmen.

2.3.3 Bewertungsmetriken

Zur objektiven Bewertung der Leistungsfähigkeit von Objekterkennungsmodellen werden standardisierte Evaluationsmetriken verwendet. Diese Metriken ermöglichen einen quantitativen Vergleich zwischen verschiedenen Modellen und Trainingskonfigurationen und sind insbesondere für die Analyse der Detektionsgenauigkeit und der Lokalisierungsqualität von zentraler Bedeutung. In dieser Arbeit werden die Metriken Intersection over Union (IoU), Precision, Recall sowie Mean Average Precision (mAP) eingesetzt, da sie sich als etablierter Standard in der Objekterkennung bewährt haben [5, 17].

Intersection over Union (IoU) Die Intersection over Union (IoU) misst den Überlappungsgrad zwischen einer vorhergesagten Bounding Box und der zugehörigen Ground-Truth-Box. Sie ist definiert als das Verhältnis der Fläche der Schnittmenge zur Fläche der Vereinigung beider Boxen. Eine hohe IoU weist auf eine präzise räumliche Lokalisierung des Objekts hin. In der Praxis wird eine Detektion häufig dann als korrekt gewertet, wenn die IoU einen vordefinierten Schwellenwert überschreitet, beispielsweise 0,5.

Precision Die Precision beschreibt den Anteil korrekt erkannter Objekte an allen vom Modell vorhergesagten Objekten. Sie gibt an, wie zuverlässig die vom Modell gemeldeten Detektionen sind und wie viele davon tatsächlich relevant sind. Eine hohe Precision deutet darauf hin, dass das Modell nur wenige Fehllalarme (False Positives) erzeugt.

Recall Der Recall misst den Anteil der korrekt erkannten Objekte an allen tatsächlich vorhandenen Objekten im Datensatz. Diese Metrik beschreibt, wie vollständig das Modell relevante Objekte detektiert. Ein hoher Recall ist insbesondere in sicherheits- oder gesundheitsrelevanten Anwendungen von Bedeutung, da möglichst wenige relevante Objekte übersehen werden sollen.

Mean Average Precision (mAP) Die Mean Average Precision (mAP) ist eine zusammenfassende Bewertungsmetrik zur Beurteilung der Gesamtleistung eines Objekterkennungsmodells. Sie kombiniert die Aspekte der Detektionsgenauigkeit (Precision) und der Vollständigkeit (Recall) und ermöglicht damit eine ganzheitliche Bewertung der Modellleistung.

Zur Berechnung der mAP wird für jede Objektklasse die sogenannte Average Precision (AP) bestimmt. Diese ergibt sich aus der Precision-Recall-Relation und beschreibt, wie gut ein Modell relevante Objekte erkennt, ohne dabei eine hohe Anzahl an Fehllarmen zu erzeugen. Die mAP ergibt sich anschließend als Mittelwert der AP-Werte über alle betrachteten Klassen.

Durch die Zusammenfassung der Detektionsleistung über alle Klassen hinweg stellt die mAP eine robuste Kennzahl dar, die sowohl die Klassifikationsqualität als auch die räumliche Genauigkeit der Objekterkennung berücksichtigt. Aus diesem Grund wird die mAP in dieser Arbeit als zentrale Metrik zur Bewertung der eingesetzten YOLOv8-Modelle verwendet.

In dieser Arbeit dienen die genannten Metriken zur systematischen Analyse der Leistungsfähigkeit der eingesetzten YOLOv8-Modelle bei der Detektion potenzieller Brutstätten von *Aedes aegypti* in drohnenbasierten Bild- und Videodaten.

2.4 Machine Learning Workflow

Machine-Learning-Workflows dienen als strukturierter Ansatz zur Entwicklung, Evaluation und Analyse von Machine-Learning-Modellen. Sie gliedern den gesamten Lernprozess in klar definierte Phasen und ermöglichen eine systematische Bearbeitung komplexer Datenverarbeitungs- und Modellierungsaufgaben. In der Literatur werden Machine-Learning-Workflows häufig als datengetriebene Prozesse mit iterativen Rückkopplungsschleifen beschrieben, die eine kontinuierliche Optimierung der einzelnen Verarbeitungsschritte erlauben [18].

Die in dieser Arbeit verwendete Workflow-Struktur orientiert sich an etablierten Modellen aus Wissenschaft und Industrie, insbesondere am Machine-Learning-Workflow nach Amershi et al. [18], dem von Google vorgeschlagenen ML-Workflow [19] sowie am Cross-Industry Standard Process for Data Mining (CRISP-DM) [20]. Diese Modelle definieren den Machine-Learning-Prozess als eine Abfolge logisch zusammenhängender Phasen, die durch Feedback- Mechanismen miteinander verbunden sind.

Wie in Abbildung ?? dargestellt, gliedert sich der Workflow in fünf zentrale Phasen: Datenerhebung, Datenvorverarbeitung, Modelltraining, Evaluation und Deployment. Die erste Phase umfasst die Sammlung der Rohdaten aus unterschiedlichen Quellen, wie beispielsweise drohnenbasierten Bild- und Videodaten. In der zweiten Phase werden die Daten für das Modelltraining aufbereitet, etwa durch die Extraktion von Videoframes, die Bereinigung fehlerhafter Annotationen oder die Anpassung von Bildauflösungen.

Darauf aufbauend erfolgt das Modelltraining, bei dem ein tiefenlernungsbasiertes Objekterkennungsmodell auf den vorbereiteten Daten optimiert wird. Die anschließende Evaluationsphase dient der quantitativen Bewertung der Modellleistung anhand definierter Bewertungsmetriken. Zwischen der Vorverarbeitung, dem Training und der Evaluation bestehen iterative Rückkopplungsschleifen, die es erlauben, Datenaufbereitung und Trainingsstrategien schrittweise zu verbessern.

Der in dieser Arbeit eingesetzte Workflow ist speziell auf die Verarbeitung videobasierter und spärlich annotierter Datensätze ausgerichtet. Insbesondere bei der automatischen Detektion potenzieller Brutstätten von *Aedes aegypti* ist eine iterative Anpassung der Datenvorverarbeitung und der Trainingsparameter erforderlich, um robuste Modelle trotz begrenzter manueller Annotationen zu erzeugen. Die letzte Phase des Deployments ist nicht Bestandteil dieser Arbeit und wird daher nicht weiter betrachtet.

Literatur

- [1] Darío Vezzani und Nicolás Schweigmann. „Suitability of containers from different sources as breeding sites of *Aedes aegypti* (L.) in a cemetery of Buenos Aires City, Argentina“. In: *Memórias do Instituto Oswaldo Cruz* 97.6 (2002), S. 789–792. DOI: 10.1590/S0074-02762002000600011.
- [2] Igor A. D. Paploski u. a. „Storm drains as larval development and adult resting sites for *Aedes aegypti* and *Aedes albopictus* in Salvador, Brazil“. In: *Parasites & Vectors* 9.1 (2016), S. 419. DOI: 10.1186/s13071-016-1705-0.
- [3] Luciano P. G. Cavalcanti, Roberto da M. A. B. Oliveira und Carlos H. Alencar. „Changes in infestation sites of female *Aedes aegypti* in Northeast Brazil“. In: *Revista da Sociedade Brasileira de Medicina Tropical* 49 (2016), S. 498–501. DOI: 10.1590/0037-8682-0221-2016.
- [4] Marco A. Valença u. a. „Dynamics and characterization of *Aedes aegypti* key breeding sites“. In: *Neotropical Entomology* 42.3 (2013), S. 311–316. DOI: 10.1007/s13744-013-0118-4.
- [5] Zhengxia Zou u. a. „Object Detection in 20 Years: A Survey“. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2023). arXiv:1905.05055. URL: <http://arxiv.org/abs/1905.05055>.
- [6] Yann LeCun u. a. „Gradient-Based Learning Applied to Document Recognition“. In: *Proceedings of the IEEE* 86.11 (1998), S. 2278–2324. URL: <https://ieeexplore.ieee.org/document/726791>.
- [7] Alex Krizhevsky, Ilya Sutskever und Geoffrey Hinton. „ImageNet Classification with Deep Convolutional Neural Networks“. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2012, S. 1097–1105. URL: <https://arxiv.org/abs/1207.0580>.
- [8] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [9] Stevo Bozinovski und Ante Fulgosi. „The influence of pattern similarity and transfer learning upon training of a base perceptron b2“. In: *Proceedings of Symposium Informatica 3* (1976), S. 121–126.
- [10] Sinno Jialin Pan und Qiang Yang. „A Survey on Transfer Learning“. In: *IEEE Transactions on Knowledge and Data Engineering* 22.10 (2010), S. 1345–1359. DOI: 10.1109/TKDE.2009.191. URL: <https://ieeexplore.ieee.org/document/5288526>.
- [11] Chuanqi Tan u. a. „A Survey on Deep Transfer Learning“. In: *Artificial Neural Networks and Machine Learning – ICANN 2018*. Springer, 2018, S. 270–279. DOI: 10.1007/978-3-030-01424-7_27.
- [12] Ultralytics. *Transfer Learning with Frozen Layers*. Accessed: 2024-05-13. 2024. URL: https://docs.ultralytics.com/yolov5/tutorials/transfer_learning_with_frozen_layers.
- [13] Joseph Redmon u. a. „You Only Look Once: Unified, Real-Time Object Detection“. In: *arXiv preprint* (2016). arXiv: 1506.02640 [cs.CV]. URL: <https://arxiv.org/abs/1506.02640>.
- [14] Joseph Redmon und Ali Farhadi. „YOLOv3: An Incremental Improvement“. In: *arXiv preprint* (2018). arXiv: 1804.02767 [cs.CV]. URL: <https://arxiv.org/abs/1804.02767>.

- [15] Alexey Bochkovskiy, Chien-Yao Wang und Hong-Yuan Mark Liao. „YOLOv4: Optimal Speed and Accuracy of Object Detection“. In: *arXiv preprint* (2020). arXiv: 2004.10934 [cs.CV]. URL: <https://arxiv.org/abs/2004.10934>.
- [16] Ultralytics. *YOLOv8 Documentation*. Accessed 2024. 2023. URL: <https://docs.ultralytics.com>.
- [17] Tsung-Yi Lin u. a. „Microsoft COCO: Common Objects in Context“. In: *International Journal of Computer Vision* 123.3 (2015), S. 740–755. URL: <http://arxiv.org/abs/1405.0312>.
- [18] Saleema Amershi u. a. „Software Engineering for Machine Learning: A Case Study“. In: *Proceedings of the 41st International Conference on Software Engineering: Software Engineering in Practice*. 2019, S. 291–300. URL: <https://ieeexplore.ieee.org/document/8804457>.
- [19] Google. *Machine Learning Workflow / AI Platform*. 2024. URL: <https://cloud.google.com/ai-platform/docs/ml-solutions-overview>.
- [20] Rüdiger Wirth und Jochen Hipp. „CRISP-DM: Towards a Standard Process Model for Data Mining“. In: *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*. 2000, S. 29–39.

Eigenständigkeitserklärung

Hiermit versichere ich, dass ich die Hausarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe, alle Ausführungen, die anderen Schriften wörtlich oder sinngemäß entnommen wurden, kenntlich gemacht sind und die Arbeit in gleicher oder ähnlicher Fassung noch nicht Bestandteil einer Studien- oder Prüfungsleistung war.

STADT, den 2025-12-23

VORNAME NACHNAME